LABORATUVAR 7 · ARMA MANTAR BARİYER · KİMYA TESİSİ GİRİŞİ

AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad Mehmet Onur Boyraz · 245541023 | Grup | Tarih 20.10.2026

Kavram — Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari **YZ'nin dışında** tanımlanmalıdır. Araçlar: **fail-safe · human override · monitoring · confidence threshold · fallback**.

Senaryo: *Kapıya ARM.v19™ yapay zekâsının eklenmesi planlanıyor; proje aşaması değerlendirmesi yapıyorsunuz. Arma, ARM.v19™ ile ürünlerinin "bazı durumlarda kendileri karar verdiğini" ve iş güvenliğini "garanti altına aldığını" söylüyor* G *. Planlanan kullanım* V *: kamera görüntüsünden plaka tanıma, araç sınıflandırma ve takip eden araç (tailgating) tespiti; çıktı bariyere "aç" ya da "kapalı tut" talebi olarak gidiyor.*



YZ'nin çıktısı yalnızca bir **talep**tir. Talebin harekete dönüşüp dönüşmeyeceğine, YZ'nin dışındaki kırmızı kapı karar verir.

Görev — üç başarısızlıkta güvenli davranış

1 **Model yanlış sınıflandırdı: Yetkisiz bir araca "YETKİLİ" dedi (ör. klonlanmış plaka). Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?**

YZ tek başına kapıyı açamaz. Üç katmanlı ikinci kontrol var:

1. **Bağımsız ikinci faktör:** plaka + o güne ait tanker randevusu + araç etiketi/kart (Arma'nın OGS/HGS ve kart okuyucu uyumu G). Üç faktörden en az ikisi uyuşmazsa "aç" talebi oluşmaz.
2. **İnsan onayı:** tanker ve tanınmayan araçlarda görevli görüntüyü görüp onaylar. Proje aşamasında bu, tüm açılışlar için geçerli.
3. **Sas kilidi:** dış hat açılsa bile görevli içerideki aracı doğrulamadan iç hat inmez. Tek bir yanlış "YETKİLİ" tesise erişim için yetmez.

Ters yön, yani emniyet: YZ "araç geçti, alan boş" derse bu karar ona bırakılmaz. Yükselme izni SF-1'in sensörlerinden (loop + fotosel + radar) gelir. YZ'nin yanlışı en fazla bir talebi bozar; hareketi bozamaz.

2 **Girdi manipüle edildi: Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?**

> **Nasıl fark edilir?**
>
> - **Tazelik:** her karede zaman damgası ve sıra sayacı var; donmuş ya da tekrar eden kare (aynı hash) alarm üretir. Tekrar oynatılan video böyle yakalanır.
> - **Akış bütünlüğü:** kamera ile YZ kutusu arasındaki akış Z2 içinde, kimliği doğrulanmış ve imzalı. LAB 2'de kameranın varsayılan parolası zaten kaldırıldı.
> - **Fiziksel çapraz kontrol:** loop "araç var" derken kamerada araç yoksa, ya da tersi, girdi tutarsız sayılır.
> - **Faktör uyumu:** plaka ↔ etiket/kart ↔ randevu ↔ araç tipi ve rengi. Basılı sahte plaka kızılötesi görüntüde gerçek, yansıtıcı plakadan farklı görünür.
> - **Görüntü kalitesi:** bulanıklık, aşırı parlama (lazer ya da IR ile kör etme), kapatılmış lens → kalite skoru düşer.
>
> **Şüpheli girdide ne yapılır?** YZ'nin çıktısı yok sayılır; bariyer **kapalı kalır**. Görevli aracı elle doğrular, güvenlik merkezine alarm gider ve olay kaydı açılır (LAB 6'nın tetikleyicisi). Şüpheli bir girdi hiçbir koşulda hareket üretmez.

3 **Confidence düştü: Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?**

> Eşik **asimetrik** olmalı. Yanlış bir "YETKİLİ" BEKRA kapsamındaki bir tesiste felakete yol açabilir (S = 3); yanlış bir "red" ise yalnızca birkaç dakikalık gecikme demektir. Bu yüzden kabul eşiği yüksek tutulur ve belirsiz bölge insana bırakılır:



- **< 0,80**, görüntü yok ya da kalite düşük → **fallback:** bariyer kapalı kalır; kart/etiket + görevli prosedürüne dönülür (YZ'siz yol).
- **0,80–0,95 → insana sor:** görevli, görüntüyü ve skoru WOC'ta görür; onaylar ya da reddeder.
- **≥ 0,95** ve ikinci faktör uyuşuyor → **otomatik "aç talebi"**; bu talep de SF-1'den ve sas kilidinden geçer.

> **Eşiklerin dayanağı** V**:** değerler sahada gece, yağmur ve toz koşulları da dahil ölçülerek kalibre edilir; hedef, yanlış kabul oranının 1/10.000'in altında kalması. Aylık gözden geçirilir. Eşik değişikliği yalnız yerinde ve değişiklik kaydıyla yapılır (LAB 4, GR-3 mantığı). Güven dağılımı kayarsa (drift) alarm üretilir.
>
> **Kritik ayrıntı:** düşük güven hiçbir zaman "yüksel" anlamına gelmez. Bariyer yalnızca bulunduğu durumda, yani kapalı kalır. "Dur" burada güvenli yöndür.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığımız güvenli davranış	Hangi kavramla?
Model yanlış sınıflandırdı	YZ tek başına açamaz: üç bağımsız faktörden en az ikisi + yüksek riskli araçta görevli onayı. Sas kilidi iç hattı kapalı tutar. Yükselme kararı YZ'de değil, SF-1'de. Her karar görüntüsüyle kaydedilir; yanlış kabul oranı aylık izlenir.	human override · fail-safe · monitoring
Girdi manipüle edildi	Tazelik, bütünlük ve fiziksel çapraz kontrol. Şüphede YZ çıktısı yok sayılır, bariyer kapalı kalır, görevli doğrular; alarm ve olay kaydı açılır.	monitoring · fail-safe · fallback
Confidence düştü	≥ 0,95 ve ikinci faktör → otomatik aç talebi · 0,80–0,95 → insana sor · < 0,80 → kapalı kal + kart/görevli prosedürü. Eşikler yalnız yerinde değişir; drift izlenir.	confidence threshold · human override · fallback
+1 · YZ kutusu çöktü ya da sinyal kesildi	Kalp atışı (heartbeat) kesilince YZ yolu otomatik devre dışı kalır. Kapı YZ'siz moda (kart + görevli) geçer; bariyer konumunu korur, kendiliğinden hareket etmez (SF-3).	fail-safe · fallback

ARM.v19™'un "iş güvenliğini garanti altına alır" iddiasına cevabımız

YZ bir tahmin üretir ve tahmin garanti edemez. Bu kapıda garantiyi YZ'nin dışındaki dört şey veriyor:

1. **SF-1 (Z0):** alan doluyken hiçbir talep hareket üretmez (LAB 1).
2. **Varsayılan "kapalı kal":** şüphe, arıza ya da düşük güven kapıyı açmaz.
3. **Görevli onayı ve override:** belirsiz ve yüksek riskli kararlar insanda.
4. **Sas kilidi:** tek bir yanlış karar tesise erişim için yetmez (LAB 3).

Bu mimaride YZ'nin işi kapıyı hızlandırmak, görevliyi rahatlatmak ve şüpheliyi işaretlemek; insanı korumak değil. Bu, YZ'yi değersiz kılmaz; sadece doğru yere koyar. Üreticinin cümlesi bir pazarlama ifadesi olarak okunmalı; mühendislik dilinde "garanti" ancak YZ'nin dışındaki doğrulanmış bir emniyet fonksiyonuyla verilebilir.

Mevzuat bunu destekliyor: AB Makine Yönetmeliği 2023/1230, emniyet fonksiyonu sağlayan ve makine öğrenmesiyle kendini geliştiren bileşenleri Ek I Bölüm A'ya koyar; bunlar için üçüncü taraf uygunluk değerlendirmesi zorunludur. AB Yapay Zekâ Yasası (2024/1689) da böyle bir ürünün emniyet bileşeni olan YZ'yi "yüksek riskli" sayar (Madde 6(1)). YZ'yi emniyet zincirinin dışında tutmak hem mühendislik hem mevzuat açısından doğru karar. Ayrıca bkz. ISO/IEC TR 5469:2024 (YZ ve fonksiyonel emniyet). G üreticinin sitesinde yazan bilgi · V eğitim senaryosu varsayımı; ARM.v19™'un gerçek iç yapısı hakkında iddia değildir.

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.